

Atividade 6 - Módulo 6: Projeto Final, Modelo Customizado para Domínio Específico

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #06 - a última desta disciplina

Esta é a missão prática final: em vez de aplicar um passo isolado, ela pede pra vocês repetirem o arco inteiro da disciplina, do Módulo 1 ao Módulo 6, num caso real do próprio trabalho, não no caso da Amplitude Seguros. O objetivo não é reproduzir cada detalhe técnico, é aplicar a mesma disciplina de decisão medida, não intuída, a um problema que é de vocês.

Tempo e custo esperados

O Passo 1 (framework) e o Passo 3 (avaliação) são raciocínio e chamadas leves, questão de minutos, sem custo relevante. Se rodarem um fine-tuning de verdade no Passo 2, contem com algo entre cerca de 13 minutos e 1 hora e 40 minutos de espera pelo job, dependendo do volume de dados e de rodar jobs isolados ou em paralelo, e um custo de poucos reais, não dezenas. Como referência, o projeto inteiro desta disciplina, somando o piloto de 200 exemplos (Módulo 3) e o modelo final escalado para 3.000 exemplos (Módulo 6), faturou 501.801 tokens de treino, R\$43,78 no total, conferido direto no billing real do Google Cloud (ver decisoes-de-arquitetura.md).

Passo 1 - Decidam com o framework do Módulo 1

Aplicuem o framework de quatro perguntas (tarefa estreita ou aberta; prompt/RAG já esgotado; dado suficiente; tarefa estável) a um caso real do trabalho de vocês, com dado de verdade, não hipotético. Derivem os pesos por AHP, ou, se preferir simplificar, usem pesos iguais documentando essa simplificação. Se o caso reprovar, documentem por quê, e parem aqui: uma reprovação bem justificada é uma entrega completa e válida.

Passo 2 - Preparem um piloto, se aprovado

Curem um pequeno conjunto de exemplos reais do seu domínio. Se dado real não for suficiente, [guia-geracao-sintetica-via-llm.md](#) explica como gerar exemplo sintético via LLM sem perder a garantia de rótulo correto, um caminho complementar, não substituto, pra quando falta volume real. Aplicuem alguma forma de deduplicação (mesmo que mais simples que MinHash e LSH) e alguma forma de balanceamento entre fontes, documentando a lógica usada. Treinem de verdade, se tiverem acesso a alguma API de fine-tuning gerenciada, ou documentem claramente por que estão simulando, com números plausíveis e justificados.

O volume certo não é um número fixo copiado deste curso: em [m6-dataset-scaling-tool.js](#) e [m6_dataset_scaling_tool.py](#) está o gerador real que produziu o dataset de produção desta disciplina (3.000 exemplos curados, documentado em [dataset-de-producao-leia-me.md](#)). Usem esse código como referência de estrutura, não como teto: editem fontes, personas de redação e alvo de balanceamento pro volume que o caso de vocês realmente sustentar, medido, não copiado.

Passo 3 - Avaliem com o protocolo de três frentes do Módulo 5

Construam um pequeno conjunto de teste retido, dado nunca visto no treino. Comparem contra uma baseline, um modelo genérico, ou uma abordagem sem fine-tuning. Construam pelo menos um teste de estresse escrito à mão, não gerado por template, e investiguem a causa raiz de qualquer queda antes de aceitar o número.

Passo 4 - Documentem as decisões, no formato deste vídeo

A entrega que fecha a disciplina inteira: escrevam um documento de decisões de arquitetura cobrindo pelo menos três decisões do próprio projeto de vocês, no mesmo formato de decisoes-de-arquitetura.md: Escolha, Alternativa rejeitada, Por quê, Resultado real. Cada decisão precisa de um número real por trás, não uma opinião solta.

Expansão opcional - Reavaliação pós-escala

Este projeto pede documento de decisões, não reavaliação contínua em produção; só isso já fecha a entrega. Se quiserem ir além, guia-reavaliacao-pos-escala.md explica o passo a passo de como remedir um modelo já escalado meses depois do gate, com um esqueleto de código ilustrativo, não obrigatório pra esta entrega.

Entrega

- Framework de 4 perguntas aplicado a um caso real, com scores e justificativa (Passo 1)
- Se aprovado: dataset curado, com dedup e balanceamento documentados (Passo 2)
- Teste retido, comparação contra baseline, e teste de estresse escrito à mão (Passo 3)
- Documento de decisões de arquitetura, pelo menos 3 decisões, no formato Escolha/Alternativa/Por quê/Resultado (Passo 4)
- Reflexão final: qual das oito decisões desta disciplina (Módulos 1 a 6) mais se pareceu com uma decisão real que vocês já tomaram, ou vão precisar tomar, no próprio trabalho?

Dica de execução

Esta missão é deliberadamente mais aberta que as cinco anteriores: não existe um único caminho certo, porque o caso de cada um é diferente. O que não muda é o padrão de rigor: cada afirmação precisa vir de algo medido, não de algo assumido. Se o caso de vocês reprovar no Passo 1, ou se não for possível treinar de verdade no Passo 2, documentar essa limitação com honestidade, e não com desculpa, é exatamente o espírito que esta disciplina cultivou do primeiro ao último vídeo.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager