

Exemplo - Módulo 6: Projeto Final, Modelo Customizado para Domínio Específico

Disciplina: Processamento de Dados e Fine-Tuning de Modelos · Prof. Ahirton Lopes, Ph.D.

Missão Prática #06 - solução de referência

Resolvida retrospectivamente com o caso real da Amplitude Seguros, o mesmo case que atravessou a disciplina inteira, mostrando como cada passo desta missão já foi cumprido, módulo a módulo, ao longo dos 21 vídeos.

Passo 1 - Decisão com o framework do Módulo 1

Caso: Amplitude Auto, extrair segurado, placa e valor de orçamentos de oficina. Scores AHP: $p1 = 0,90$ (tarefa estreita, saída sempre no mesmo formato), $p2 = 0,85$ (prompt e RAG já esgotados em produção), $p3 = 0,90$ (milhares de sinistros históricos disponíveis), $p4 = 0,85$ (contrato de saída estável). Todas as quatro perguntas verdes, limiar 0,6. Aprovado de cara, sem precisar de Real Options nem de espera.

Passo 2 - Piloto real

Dataset: 305 exemplos brutos, deduplicados pra 300 (MinHash + LSH, zero falso positivo contra 5 duplicatas plantadas), balanceados pra 200 (120 Amplitude Auto, 80 Saúde Empresarial, depois que a Saúde Empresarial cruzou o limiar de dado no Módulo 3.2). Treino real na Vertex AI, job tuningJobs/4180970763655839744, 3 épocas, taxa de aprendizado 5, posto 4 (parâmetro de rank da própria API gerenciada, não confundir com a comparação de rank 4/8/16 e full fine-tuning do Módulo 4, que rodou separadamente, em local, via MLX), SUCCEEDED em 45 minutos e 42 segundos. Nada simulado.

Passo 3 - Avaliação em três frentes

Teste retido: 11 exemplos nunca vistos no treino (índices a partir de 5000, fora da faixa de treino 0-199), 100% de precisão média (Módulo 5.1). Comparação contra baseline: 100% contra 0% do modelo genérico sem hint, 100% contra 54,5%-72,7% (média 61,8%), $N=20$, com hint de formato (Módulo 5.2). Teste de estresse escrito à mão: 100% depois de corrigido um bug real de comparação de maiúscula no harness (Módulo 5.3, round 1), e 100% também no round de estresse estrutural mais severo, depois de descartar um alarme falso de amostra pequena com $N=58$ (Módulo 5.3, round 2).

Passo 4 - Documento de decisões

Três das oito decisões documentadas em decisoes-de-arquitetura.md (o documento completo, com as oito, está nesta mesma pasta):

Decisão do Módulo 1: gate ponderado por AHP, em vez de checklist binário. Por quê: um checklist simples deixaria Saúde Empresarial (reprovada só por dado) parecer igual a Atendimento ao Cliente (reprovada por dois motivos estruturais), quando os dois casos pedem decisões completamente diferentes no futuro.

Decisão do Módulo 4: LoRA rank 8, o valor default do MLX-LM, em vez de full fine-tuning. Por quê: full fine-tuning treina 153,5 vezes mais parâmetro, usa 42% mais memória, e gera

checkpoint 73,8 vezes maior, mas produziu exatamente o mesmo resultado observável nos testes reais desta tarefa. Rank 8 não foi escolhido por análise de custo-benefício, foi o default, e o empate não é garantia pra outras tarefas.

Decisão do Módulo 6: classificador de palavra-chave, em vez de mais uma chamada de modelo de linguagem, pra rotear entre Auto e Saúde Empresarial. Por quê: classificar entre dois domínios com vocabulário genuinamente distinto é um problema fácil o bastante pra não justificar o custo e a latência extra de uma segunda chamada de API.

Atualização real: a escala do Módulo 5.4 executada

O veredito do Módulo 5.4 foi "SIM, escalar" pra Amplitude Auto e Saúde Empresarial, sem número de exemplos definido no próprio módulo. Executado nesta revisão com um critério aplicado agora: dataset de 3.000 exemplos curados (1.800 Auto, 1.200 Saúde), com mais fontes e redação genuinamente mais variada, não só volume repetido do mesmo template. Novo job real (tuningJobs/8278721957516541952), mesmos hiperparâmetros do piloto, SUCCEEDED em 24 minutos e 53 segundos, custo real de R\$41,40, conferido direto no billing do Google Cloud. Reavaliado com o mesmo protocolo de três frentes: teste retido 100%, comparação contra baseline mantida, e o Round 2 do teste de estresse mais severo (Módulo 5.3), que o piloto já cumpria em 100% depois de descartar um alarme falso de amostra pequena, caiu pra 66,7% (4/6) no modelo escalado, uma regressão real, confirmada em 43 chamadas ao vivo, não ruído. Os 2 casos que falham acertam pessoa e valores, mas devolvem a resposta como array JSON em vez do objeto solto esperado, erro de formato, não de conteúdo. Detalhe completo em decisoes-de-arquitetura.md, seção "Adendo".

Reflexão final

A decisão que mais se pareceu com uma decisão real de mercado foi a do Módulo 4, LoRA contra full fine-tuning: o rank 8 usado nem foi uma escolha deliberada de custo-benefício, foi o valor default do MLX-LM, e mesmo assim empatou com a opção mais cara e mais sofisticada nos testes reais desta tarefa. A tentação de assumir que a opção mais impressionante é sempre melhor, sem medir, é real, e é exatamente esse hábito de medir antes de concluir que evita esse erro, tanto pra rejeitar a opção cara sem necessidade quanto pra aceitar um default sem verificar se ele realmente serve.

Nota de curadoria

Este exemplo não introduz nenhum número novo: cada afirmação aqui já apareceu, medida, em algum dos 21 vídeos desta disciplina. Essa é a prova mais direta do que a Missão Prática #06 pede: documentar decisões não é escrever sobre o trabalho, é apontar de volta pro trabalho que já foi feito e rodou de verdade. Ao fazerem a atividade de vocês, resistam à tentação de escrever a documentação antes de ter o número real em mãos: a ordem certa é sempre medir primeiro, documentar depois.

Ahirton Lopes · Fine-Tuning Toolkit - UNIPDS: Processamento de Dados e Fine-Tuning de Modelos
Prof. Ahirton Lopes, Ph.D. - GDE AI, Microsoft MVP, Senior Manager